Nicolas Rodrigues de Vargas

Belo Horizonte – MG (remoto) • (51) 98300-6715 • nicolas.vargas8@gmail.com
nicodevargas.github.io • linkedin.com/in/nicodevargas • github.com/NicoDeVargas

Resumo

Engenheiro de IA: construo e coloco em produção produtos com LLMs, de ponta a ponta (agentes, RAG, voz em tempo real, AWS), e faço fine-tuning e destilação de modelos abertos. Decido por benchmark próprio: custo, latência e taxa de erro. Promovido de estagiário a júnior na AI4Sellers. Engenharia da Computação no CEFET-MG (formatura prevista dez/2028).

Experiência

AI4Sellers — Engenheiro de IA (AI Engineer) | jun/2026 – atual

Promovido de estagiário a júnior. Startup de treinamento de vendas com simuladores de IA.

- **Custo por simulação −68%** (US$ 0,44 → 0,14) nos simuladores de venda por voz, usados por mais de 100 vendedores: propus e validei por benchmark uma cascata STT → LLM → TTS no lugar do Gemini Realtime (custo, latência e resistência a ataques de prompt).
- **Alucinação de 40% para 0%** num copiloto de produtos B2B, trocando RAG puro em PostgreSQL por RAG híbrido com grafos (1.000 perguntas).
- **Agente de CRM por voz**: a IA entrevista o vendedor após a reunião e preenche o CRM; registro de 10–20 min para 2 min, campos vazios de 45% para 0%.
- **Arquitetura AWS multi-cliente** desenhada por mim (ECS, RDS, S3, Lambda, CDK): cerca de 60% menos custo nos pilotos; cliente novo no ar em 2 dias.
- **Servidor MCP em produção** (TypeScript, Lambda, OAuth com Cognito, 18 ferramentas) que liga um agente corporativo a uma base de compras públicas atualizada todo dia (Fargate → Parquet versionado → DuckDB); 5,9 mil documentos com proveniência, 1,9 mil testes.

AI4Sellers — Estagiário em Automação e IA | jun/2025 – mai/2026

- Aplicações fullstack com LLMs para clientes; pipelines de scraping e vetorização (Python, Pandas, Supabase Vector) para RAG; automações com n8n.

Projetos

- **Radar de avaliações para e-commerce** (app no ar · modelo no Hugging Face): destilei o Claude Opus num BERTimbau int8 que roda no navegador e aponta anúncio a corrigir, lote com defeito e estado onde a entrega falha. 87% de acerto num gabarito humano, igual ao LLM professor, a custo zero por avaliação.
- **Fine-tuning do Qwen3-8B com LoRA** (github.com/NicoDeVargas/qwen3-npc-dialogue-lora): ações corretas de 11% para 93% em NPCs que respondem em JSON; medi que fundir o adaptador e requantizar derrubava a acurácia de 90% para 30%.
- **Dewe — cofundador** (deweai.com): simulação clínica por voz para estudantes de medicina, com avaliação por IA (rubrica e RAG). Paciente simulado com 96% de fidelidade; motor de voz escolhido por benchmark (45% menos custo por consulta); 3.900+ testes.

Formação e certificações

CEFET-MG — Bacharelado em Engenharia da Computação | 2023.2 – dez/2028 (previsão)

UNIASSELVI — Tecnólogo em Big Data e Inteligência Analítica | 2023.1 – 2028.1 (previsão)

AWS Certified AI Practitioner e **AI Business Strategist** | previsão: nov/2026

Habilidades

- **IA:** Claude, GPT, Gemini (inclusive Realtime), agentes, MCP, RAG híbrido com grafos, LangChain, Bedrock, fine-tuning LoRA (PEFT), destilação, ONNX, llama.cpp, avaliação de modelos.
- **Engenharia:** Python, TypeScript, Node.js, React, Next.js, PostgreSQL, AWS (ECS, Lambda, RDS, S3, CDK), Docker, Linux, Git. **Inglês:** avançado.