Nicolas Rodrigues de Vargas

Belo Horizonte – MG (remoto) • (51) 98300-6715 • nicolas.vargas8@gmail.com
nicodevargas.github.io • linkedin.com/in/nicodevargas • github.com/NicoDeVargas

Resumo

Engenheiro de software com foco em IA: construo e coloco em produção produtos com LLMs, de ponta a ponta. Desenvolvedor de IA na AI4Sellers (promovido de estagiário a júnior) e estudante de Engenharia da Computação (CEFET-MG, formatura prevista dez/2028). Desenho arquiteturas na AWS, agentes, RAG e voz em tempo real, e também faço fine-tuning de modelos abertos (LoRA). Decido com benchmarks próprios, medindo custo, latência e taxa de erro. Uso agentes de código (Claude Code, Cursor) no dia a dia.

Experiência Profissional

AI4Sellers — Engenheiro de IA (AI Engineer) | jun/2026 – atual

Promovido de estagiário a júnior pela entrega e autonomia técnica. Startup de treinamento de vendas com simuladores de IA.

- **Simuladores de venda por voz com IA** usados por mais de 100 vendedores. Construí o sistema de suporte in-app (API do Google) de um simulador para uma rede de shopping centers, que aguentou mais de 100 usuários simultâneos no lançamento.
- **Custo por simulação de US$ 0,48 para US$ 0,14 (−71%)**: propus e validei com benchmark próprio uma arquitetura em cascata (STT → LLM → TTS) no lugar do Gemini Realtime, comparando custo, latência e resistência a ataques de prompt.
- **Arquitetura AWS desenhada por mim** para produção e pilotos de vários clientes (ECS, RDS, S3, Lambda, CloudFormation/CDK). Com serverless nos pilotos, cortei cerca de 60% do custo de AWS. Um cliente novo sobe em 2 dias.
- **Alucinação de 40% para 0%** no copiloto de produtos de um cliente B2B: troquei o RAG puro em PostgreSQL por um RAG híbrido com grafos. Medido numa bateria de 1.000 perguntas.
- **Agente de CRM por voz**: depois de cada reunião, a IA entrevista o vendedor e preenche o CRM. O registro caiu de 10–20 min para 2 min, e os campos vazios, de 45% para 0%.
- **Automações internas**: agente de demandas (Claude no Bedrock, Transcribe, Linear) que transforma áudio em tarefas e manda um resumo diário; gerador de aulas personalizadas em PDF e áudio a partir das simulações de cada vendedor.
- **Demos construídas em dias**: base de compras públicas (6.238 itens) consultada por um agente no Amazon Quick; jogo com votação ao vivo para ~25 executivos, publicado em uma noite; painel de LLM local em hardware NVIDIA para um evento da Dell.

AI4Sellers — Estagiário em Automação e IA | jun/2025 – mai/2026

- Desenvolvi e publiquei aplicações fullstack para clientes finais, integrando LLMs via API em fluxos de automação com n8n e LangChain.
- Construí pipelines de web scraping, tratamento e vetorização de dados (Python, Pandas, Supabase Vector) para sistemas RAG.
- Criei agentes com n8n e APIs REST que reduziram trabalho manual em processos internos e de clientes.

Artecola Química — Estagiário em Suporte a Infraestrutura e Redes | mar/2023 – jun/2023

- Suporte técnico presencial e remoto, com diagnóstico e resolução de problemas de redes e sistemas.

Projetos em Destaque

- **Dewe — cofundador** (deweai.com)**:** plataforma de simulação clínica com IA. O aluno de medicina atende por voz um paciente simulado e recebe uma avaliação comentada com base nas diretrizes clínicas. Construí a plataforma inteira (voz em tempo real, avaliação por IA com rubrica e RAG, turmas e simulação seriada). O paciente simulado teve 96% de fidelidade numa bateria de casos com armadilhas, e escolhi o motor de voz por benchmark: 96% contra 92% de acerto e 45% menos custo por consulta. Mais de 3.900 testes automatizados.
- **Radar de avaliações para e-commerce** (app no ar · modelo no Hugging Face)**:** lê as avaliações de uma loja e aponta o anúncio a corrigir, o lote com defeito e o estado onde a entrega falha. Destilei o Claude Opus num BERTimbau quantizado para int8, que roda no navegador: 87% de acerto num gabarito humano, igual ao LLM professor, a custo

zero por avaliação. Descobri que rótulos melhores pesavam mais que o modelo: com o professor fraco, o mesmo aluno ficava em 73%.

- **Fine-tuning de LLM para diálogos de jogo** (github.com/NicoDeVargas/qwen3-npc-dialogue-lora)**:** treinei o Qwen3-8B com LoRA (bf16) em cerca de 4 mil exemplos, numa GPU A10G na AWS. As ações corretas subiram de 11% (modelo base) para 93%, e o validador do jogo aprovou 97,5% das falas no modo ao vivo. O modelo roda no jogo (Godot) via llama.cpp, com o LoRA carregado em tempo de execução: medi que fundir o adaptador e requantizar derrubava a acurácia de 90% para 30%.
- **Copiloto para Meta Glasses (hackathon):** assistente de vendas por áudio com a API Realtime do Gemini. A arquitetura foi refeita no meio do caminho e entregue em 2 dias.
- **Análise tática com LLMs:** agentes que cruzam dados espaço-temporais de partidas de futebol e geram relatórios de scout automáticos.

Certificações

AWS Certified AI Practitioner (AIF-C01) | previsão: nov/2026

AWS Certified AI Business Strategist | previsão: nov/2026

Formação

CEFET-MG — Bacharelado em Engenharia da Computação | 2023.2 – em andamento (7° semestre) | formatura prevista: dez/2028

UNIASSELVI — Tecnólogo em Big Data e Inteligência Analítica | 2023.1 – em andamento | formatura prevista: 2028.1

Extensão no CEFET-MG (2023.2 – 2026.1): backend no COMPET (Scrum) e no CodeLife, plataforma gamificada que ensina programação a jovens.

Habilidades

- **Agentes e LLMs:** Claude, GPT, Gemini (inclusive Realtime), prompt engineering avançado, saída estruturada, RAG híbrido com grafos, LangChain, Amazon Bedrock e Quick.
- **Modelos abertos:** fine-tuning com LoRA (PEFT), llama.cpp, GGUF/quantização, avaliação de modelos com benchmarks e baterias de teste.
- **Engenharia de software:** Python (avançado), TypeScript, Node.js, React, Next.js, APIs REST, SQL, PostgreSQL, Clean Architecture.
- **Cloud e dados:** AWS (ECS, Lambda, RDS, S3, CloudFormation/CDK, Transcribe), Docker, Git, Linux, Railway, Supabase, Pandas, web scraping.
- **Automação e ferramentas:** n8n, Claude Code, Cursor.

Idiomas

Inglês: avançado